

Arquitectura de Modelos de Generación de Video: Paradigmas de Difusión Latente y Transformadores Espaciotemporales

El Cambio Paradigmático en la Síntesis de Video

La síntesis de video mediante inteligencia artificial generativa ha experimentado una transición estructural profunda.¹ Los enfoques iniciales sustentados en Redes Neuronales Generativas Adversarias (GAN) y modelos autorregresivos tradicionales han sido desplazados por arquitecturas avanzadas basadas en modelos de difusión.¹ Este cambio paradigmático responde a la capacidad intrínseca de los modelos de difusión para aproximar distribuciones de datos de alta dimensionalidad con una excelente estabilidad durante el entrenamiento y sin sufrir los problemas de colapso de modo característicos de las GAN.¹

El objetivo matemático fundamental de un modelo de difusión latente (LDM) aplicado a la generación de video es modelar la distribución de probabilidad de secuencias de fotogramas representadas en un espacio latente comprimido de bajas dimensiones.⁵ La formulación matemática del objetivo de entrenamiento de difusión en este espacio latente se define mediante la función de pérdida por emparejamiento de ruido:

$$\mathcal{L}_{\text{diff}} = \mathbb{E}_{z_0 \sim \mathcal{E}(x_0), t, y, \epsilon} \left[\|\epsilon - \epsilon_\theta(z_t, t, \tau_\theta(y))\|_2^2 \right]$$

6

Donde x_0 representa el video original en el espacio de píxeles, $\mathcal{E}$ es el codificador de la red de compresión visual (VAE) que proyecta el video al espacio latente z_0 , t indica el paso de tiempo del proceso de difusión, y es la condición de entrada (comúnmente una descripción textual), τ_θ es un codificador de texto como T5-XXL o CLIP que genera los embeddings condicionales, ϵ representa el ruido gaussiano añadido y ϵ_θ es el denotador parametrizado (red neuronal) que predice el ruido residual.⁵

Recientemente, el marco del emparejamiento de flujos condicionales (Conditional Flow Matching - CFM) ha surgido como una alternativa altamente eficiente frente a la difusión tradicional.⁴ A diferencia de los esquemas de difusión clásicos que aprenden a revertir un proceso estocástico de degradación paso a paso a lo largo de un camino curvo en el espacio latente, CFM aprende un campo de vectores dependiente del tiempo que transporta las

muestras de forma determinista y a través de trayectorias lineales y fluidas basadas en transporte óptimo.⁴ Esto permite generar videos de calidad superior reduciendo drásticamente el número de pasos de muestreo en inferencia.⁹

Atributo Técnico	Modelos de Difusión Tradicionales (DDPM/LDM)	Emparejamiento de Flujos Condicionales (CFM)
Dinámica de Trayectoria	Estocástica, curva y no lineal ⁴	Determinista, lineal y directa (óptima) ⁴
Pasos de Muestreo (Inferencia)	Generalmente de 50 a 250 pasos ⁹	Reducido a 10-30 pasos sin pérdida de calidad ⁹
Función de Pérdida	Pérdida de emparejamiento de ruido (Score Matching) ¹	Regresión de vectores de velocidad de flujo latente ⁴
Distribución de Pasos	Enfoque de ruido variable (ruido gaussiano) ¹	Muestreo Logit-Normal para etapas intermedias ⁹

El Paradigma de los Transformadores de Difusión (Diffusion Transformers - DiT)

La introducción de los Transformadores de Difusión (DiT) ha revolucionado la generación de video debido a sus propiedades de escalabilidad óptimas.¹¹ A diferencia de las redes convolucionales U-Net, cuya rigidez estructural limita el aprovechamiento de grandes infraestructuras de supercómputo, los transformadores exhiben una mejora lineal y predecible en la calidad del video generado y en la adherencia semántica del texto a medida que se escala el cómputo de entrenamiento.⁸

El Concepto de Parches Latentes Espaciotemporales (Spacetime Latent Patches)

Inspirados por los modelos de lenguaje de gran tamaño (LLM) que operan sobre tokens textuales unitarios, los modelos de generación de video basados en DiT procesan la información visual dividiéndola en "parches latentes espaciotemporales".¹¹ El proceso de descomposición estructural consta de las siguientes etapas:

1. El video de entrada de dimensiones $F \times H \times W \times C$ (donde F es la duración en fotogramas, $H \times W$ representan la resolución espacial y C indica los canales de color) es procesado inicialmente por un autoencoder tridimensional causal (3D Causal VAE).⁸ El codificador comprime el video tanto espacial como temporalmente, generando

un volumen latente reducido de dimensiones $f \times h \times w \times c$.⁸

2. Este tensor latente espaciotemporal se segmenta en pequeños bloques cúbicos

(denominados *tubelets* o parches de espacio-tiempo) de dimensiones $p_f \times p_h \times p_w$.¹¹

3. Cada parche cúbico se aplanar y se proyecta mediante una capa lineal hacia un espacio vectorizado de embedding de dimensión d , generando una secuencia unidimensional de tokens visuales.⁸

```
|  
v (Codificador VAE 3D)  
[Latente Comprimido: f x h x w x c]  
|  
v (Segmentación en Cubos Spacetime)  
[Parches Cúbicos: (f/p_f) x (h/p_h) x (w/p_w)]  
|  
v (Aplanamiento e Inyección Proyección Lineal)
```

Esta representación basada en parches es la clave que permite a modelos como OpenAI Sora entrenarse y generar videos en sus dimensiones, relaciones de aspecto y duraciones nativas.¹²

En lugar de recurrir a operaciones perjudiciales de recorte (*crop*) o escalado espacial que distorsionan la geometría natural de la escena o cortan partes esenciales de los sujetos, los parches se empaquetan de forma adaptativa mediante el método "patch n' pack" derivado de NaViT.¹¹ Durante el muestreo en inferencia, es posible estructurar estos parches inicializados aleatoriamente en una rejilla que replique exactamente el formato de pantalla de destino (por ejemplo, vertical de 1080x1920 o panorámico de 1920x1080).¹³

A nivel cuantitativo, si se analiza un video latente de resolución espacial 256×256 con parches de tamaño 16×16 , y un empaquetamiento espaciotemporal que convierte 16 fotogramas en un solo token (*tubelet embedding* de ViViT)¹¹, la secuencia total para un video de un minuto (60 segundos) grabado a una tasa estándar de 30 fps puede calcularse analíticamente:

$$\text{Tokens Espaciales por Fotograma} = \frac{256}{16} \times \frac{256}{16} = 256 \text{ tokens}$$

$$\text{Fotogramas Totales} = 60 \text{ s} \times 30 \text{ fps} = 1800 \text{ fotogramas}$$

$$\text{Puntos Temporales Tokenizados} = \frac{1800 \text{ fotogramas}}{16 \text{ fotogramas/token}} = 112.5 \text{ pasos temporales}$$

$$\text{Longitud de Secuencia Total} = 256 \times 112.5 = 28800 \text{ tokens visuales}$$

11

Esta longitud de secuencia (28,800 tokens) se encuentra perfectamente dentro de las capacidades de los transformadores modernos equipados con mecanismos de atención optimizados.¹¹ Al escalar las implementaciones, como en la iniciativa de código abierto Open-Sora, el sistema es capaz de extender la longitud del búfer de parches de entrenamiento hasta alcanzar los 819K patches, garantizando una excelente estabilidad en la síntesis de secuencias prolongadas.¹⁷

Limitaciones de los Modelos DiT en la Consistencia Física

A pesar de la sofisticación estructural y de su capacidad para generar tomas complejas con movimientos fluidos de cámara manteniendo la consistencia tridimensional de los objetos y fondos, los modelos basados en DiT (como Sora) exhiben debilidades significativas en la modelación de la física intuitiva del mundo real¹⁴:

- **Simulación Física Deficiente:** El modelo carece de un motor de física explícito o de restricciones de geometría proyectiva.¹⁴ Como resultado, suele fallar al simular interacciones dinámicas sencillas de causa y efecto, como la trayectoria de un objeto sólido tras una colisión, o el hecho de que una galleta que ha sido mordida por un personaje no muestre la marca de la mordida inmediatamente después.¹⁴
- **Inexactitud Espacial y Temporal:** Presenta confusiones en la orientación espacial fina (como mezclar la izquierda y la derecha en rotaciones complejas) y experimenta dificultades para mantener la coherencia en eventos que se desarrollan de manera lenta y prolongada en el tiempo (como trayectorias de cámara ininterrumpidas).¹⁴
- **El Fenómeno "Slop" Visual:** La generación sin restricciones físicas a menudo provoca deformaciones anatómicas, extremidades fantasmas que aparecen y desaparecen de forma abrupta, u objetos que se fusionan entre sí de forma físicamente imposible, lo que genera rechazo en comunidades artísticas profesionales al catalogarse como "slop visual" de aspecto misterioso e irreal.¹⁸

A continuación se adjunta la visualización correspondiente al esquema de procesamiento y codificación de fotogramas a través de un autoencoder de video en el espacio latente:

Optimizaciones en la Compresión Temporal y Espacial de Video

El diseño del autoencoder variacional (VAE) es crítico en los modelos de difusión latente.²⁰ Al encargarse de la compresión del volumen del video original de alta resolución espacial y temporal a un espacio de bajas dimensiones, la tasa de compresión y la calidad de reconstrucción del VAE determinan directamente el límite de rendimiento y la viabilidad computacional de la generación de video.²¹

3D Causal VAE de CogVideoX

CogVideoX propone e implementa un 3D Causal VAE que logra una compresión

espaciotemporal simétrica de escala $8 \times 8 \times 4$ de píxeles a latentes.⁸ El codificador y el decodificador están compuestos por una serie de etapas simétricas con bloques ResNet donde se intercalan operaciones de submuestreo y supermuestreo.⁸ Mientras algunas capas de la red operan únicamente en las dimensiones espaciales 2D, otras realizan convoluciones en las tres dimensiones espaciotemporales 3D, garantizando una codificación densa de la dinámica de movimiento sin perder fidelidad geométrica.⁸

Para evitar problemas de parpadeo temporal (*flickering*), el VAE adopta convoluciones temporalmente causales.⁸ Esto asegura que la reconstrucción y la codificación de un fotograma dependan única y exclusivamente de la información del fotograma actual y de los anteriores, evitando cualquier fuga de información desde el futuro.²⁰ Adicionalmente, el procesamiento de videos prolongados introduce un consumo inviable de memoria en GPU.⁸ Para solucionar esto, se aplica paralelismo de contexto (context parallel) en la dimensión del tiempo.⁸ Debido a la causalidad de la convolución 3D, el cómputo se distribuye entre múltiples tarjetas gráficas de forma secuencial, donde cada dispositivo solo necesita transmitir un segmento de datos de tamaño $k - 1$ (donde k es el tamaño del kernel temporal de la convolución) al siguiente nodo, manteniendo los requisitos de comunicación en niveles de latencia extremadamente bajos.⁸

El Conflicto de Inicialización de Pesos e Inestabilidad de las Redes Causal 3D VAE

Un hallazgo técnico fundamental en el entrenamiento de autoencoders de video revela un conflicto de optimización crítico cuando se inicializan redes 3D a partir de pesos de modelos 2D preentrenados de imágenes²⁰:

1. **Supresión del Aprendizaje Temporal:** Al inicializar un VAE 3D utilizando un modelo VAE 2D (enfocado exclusivamente en compresión espacial) con el mismo número de dimensiones latentes (por ejemplo, manteniendo Z canales), la red hereda un sesgo espacial masivo.²⁰ Este sesgo actúa como un obstáculo para el aprendizaje posterior,

suprimiendo de manera sistemática la capacidad de la red para aprender una compresión temporal efectiva en las dimensiones restantes.²⁰ La inicialización directa desde un modelo de imágenes con dimensiones de canal idénticas deprime la velocidad de convergencia y degrada la capacidad de reconstrucción de detalles dinámicos en los videos entrenados.²¹

2. **Asimetría Causal y Desbalance Inter-fotograma:** La estructura de la convolución causal unidireccional hacia adelante genera una distribución desigual del flujo de información dentro de un grupo de fotogramas comprimidos.²⁰ Durante el proceso de

compresión de un grupo de M fotogramas, el fotograma inicial no tiene forma de interactuar con el resto del grupo, mientras que el último fotograma hereda y acumula la información de todo el volumen.²⁰ Al decodificar el latente, esta asimetría de correlación temporal causa un rendimiento desequilibrado, donde los primeros fotogramas del grupo de reconstrucción exhiben una pérdida severa de nitidez y fidelidad en comparación con los fotogramas finales del mismo segmento.²⁰

Para superar estas limitaciones, se ha propuesto la arquitectura **Keyframe-based Temporal Compression (KTC)** acoplada al módulo de **Convoluciones Causales de Grupo (GCCConv)**

²⁰.

- **KTC:** En lugar de heredar los pesos de un canal Z idéntico de un VAE de imágenes, la arquitectura KTC divide el espacio latente en dos ramas separadas.²⁰ La primera mitad del canal ($Z/2$) hereda directamente el mapa y las prioridades de compresión espacial de fotogramas clave (*keyframes*) de un VAE de imágenes de bajas dimensiones, preservando una alta fidelidad espacial.²⁰ La otra mitad se destina de forma exclusiva a almacenar y aprender la información temporal fluida a través de convoluciones causal 3D, facilitando una inicialización equilibrada y una convergencia acelerada.²⁰
- **GCCConv:** Reemplaza la estructura causal clásica unidireccional por una estructura que divide la secuencia de fotogramas en grupos simétricos de tamaño M .²⁰ Dentro de cada grupo, se aplican convoluciones estándar simétricas y bidireccionales, forzando una distribución de información idéntica y equilibrada para todos los fotogramas.²⁰ Para asegurar la flexibilidad temporal necesaria para procesar videos de duración arbitraria, se aplican operaciones de acolchado causal lógico (causal logical padding) en las uniones de los grupos, manteniendo la causalidad inter-bloques y la suavidad en las transiciones de movimiento.²⁰

Adicionalmente, otros diseños alternativos como **PVQ-VAE (Pyramidal Vector Quantized VAE)** proponen una aproximación de compresión en el dominio de la frecuencia.²⁴ Al combinar la Transformada Rápida de Fourier (FFT) para capturar las estructuras globales redundantes de baja frecuencia y la Transformada de Wavelet Discreta (DWT) para codificar los detalles locales adaptables en múltiples escalas espaciotemporales, PVQ-VAE es capaz de lograr tasas de

compresión masivas de hasta $32\times$ espacial y $16\times$ temporal, reteniendo una excelente

nitidez perceptual gracias al uso de cuantización libre de tabla de búsqueda (Lookup-Free Quantization - LFQ).²⁴

El Paradigma de U-Net Espaciotemporal (Space-Time U-Net - STUNet)

El modelo Google Lumiere introdujo una solución conceptualmente diferente para atajar el problema de la consistencia temporal global en la síntesis de video, proponiendo la arquitectura de U-Net Espaciotemporal (STUNet).²⁵

Generación en una Sola Pasada vs. Cascadas Temporales

Los sistemas tradicionales de generación de video operan bajo un diseño fragmentado y secuencial en cascada.²⁶ Un modelo base genera una secuencia de fotogramas clave muy espaciados en el tiempo y a baja resolución (por ejemplo, muestreando cada quinto fotograma de la escena de destino).²⁶ Posteriormente, un modelo de superresolución temporal (TSR) realiza una tarea de interpolación de fotogramas intermedios para aumentar los cuadros por segundo, y finalmente, una red de superresolución espacial (SSR) incrementa la resolución espacial píxel por píxel.²⁶

Este procesamiento fragmentado acumula errores sistemáticos en cada etapa de la cascada.²⁶ Al procesar los parches espaciales de forma independiente o en ventanas no solapadas, se pierden las dependencias del movimiento real del objeto, provocando que los videos finales presenten parpadeo, deformaciones anatómicas rápidas e inconsistencias temporales severas.²⁶

SISTEMA DE CASCADA TRADICIONAL:

--> --> [Fotogramas Clave a 3 fps (128x128)]

|
v

|
v

|
v

(Video final propenso a flickering)

SISTEMA LUMIERE (STUNet):

-->

|
v

|
v

(Video coherente de 5 segundos de duración)

Lumiere supera esta barrera procesando la duración temporal completa del video (80 fotogramas a 16 fps, equivalentes a 5 segundos de video de toma continua) de forma unificada en una sola pasada a través de STUNet.²⁶ Al considerar simultáneamente la posición espacial y la evolución temporal de los objetos en todas las capas del modelo, la dinámica de movimiento resulta físicamente verosímil y carece de artefactos de salto visual.²⁶

Reducción de Escala Espaciotemporal y Convoluciones Factorizadas

Para contener la inmensa carga computacional asociada al procesamiento simultáneo de 80 fotogramas a alta resolución, STUNet modifica la arquitectura U-Net clásica integrando bloques de submuestreo y supermuestreo en la dimensión del tiempo además de las espaciales.²⁵ Esto desplaza la mayor parte de las operaciones de cálculo intensivo (como el cómputo de la autoatención densa) hacia una representación espaciotemporal altamente concentrada y de bajas dimensiones en el "cuello de botella" central de la U-Net.²⁶

Para conservar los pesos previamente entrenados de los modelos de texto a imagen (T2I), STUNet adopta **Convoluciones Factorizadas**²⁷:

- Cada bloque convolucional 3×3 de imágenes de la U-Net original se reconfigura para actuar únicamente en el espacio espacial como una convolución 3D de tamaño $1 \times 3 \times 3$.²⁷
- Inmediatamente después, se inyecta una convolución temporal factorizada de tamaño $3 \times 1 \times 1$ que procesa la dimensión del tiempo.³⁰

Este diseño preserva intacta la capacidad de representación visual del modelo de imágenes estáticas base, añadiendo un canal de interacción temporal altamente expresivo y computacionalmente eficiente.²⁶

Súper Resolución Espacial Mediante MultiDiffusion Temporal

Dado que el procesar la secuencia completa de 80 fotogramas en alta resolución espacial mediante redes convolucionales de súper resolución (SSR) desbordaría la memoria de cualquier hardware de consumo, Lumiere propone extender el algoritmo **MultiDiffusion** hacia el dominio del tiempo.²⁶

En lugar de procesar los fotogramas del video en bloques temporales aislados, el modelo divide el video en ventanas que se solapan en el tiempo (por ejemplo, procesando segmentos solapados de 8 fotogramas donde existe una coincidencia de 2 fotogramas entre ventanas adyacentes).²⁷ Tras predecir de forma independiente la súper resolución para cada segmento, el sistema promedia matemáticamente los campos de ruido predichos en las intersecciones antes de realizar el siguiente paso de eliminación de ruido.²⁷ Este promedio de trayectorias garantiza una continuidad perfecta y una homogeneidad absoluta en el color, texturas y formas a lo largo de toda la secuencia del video.²⁶

A continuación se muestra el esquema arquitectónico detallado de la red Space-Time U-Net (STUNet) de Google Lumiere:

!(https://www.researchgate.net/figure/Space-Time-UNet-STUNet-architecture-Bar-Tal-et-al-2024-Lumiere-2024_fig1_379089749)³¹

Modelos Inflados y Post-Ajuste Paramétricamente Eficiente

Para muchos entornos de desarrollo, el entrenamiento desde cero de un modelo DiT masivo resulta prohibitivo.¹⁷ Una estrategia altamente eficiente consiste en tomar un modelo de difusión de imágenes de alto rendimiento preentrenado y realizar un "inflado" de la red para inyectarle dinámicas de movimiento temporales.³⁰

Inflación de Redes e Inserción de Capas Temporales en Stable Video Diffusion (SVD)

Stable Video Diffusion (SVD) se construye tomando como base un modelo de imágenes estáticas y transformando su arquitectura para operar en el volumen espaciotemporal de video.⁷ La red original procesa tensores con dimensiones

(donde B es el tamaño del lote, C representa los canales, y $H \times W$ la resolución espacial). Durante el inflado a video, el tensor se redimensiona a la forma

(donde T indica la secuencia temporal de fotogramas), permitiendo que las convoluciones espaciales actúen de forma independiente sobre cada cuadro individual.³⁰

Para capturar la coherencia de movimiento entre cuadros, SVD inserta bloques de atención temporal después de cada bloque de autoatención espacial de la U-Net.³⁰ En estas nuevas

capas, las dimensiones espaciales H y W se unifican como dimensiones de lote, de modo que el mecanismo de atención opere exclusivamente a lo largo del eje del tiempo (fotogramas T).³⁰ Durante el entrenamiento inicial de estas capas temporales, todos los pesos de las capas espaciales preentrenadas se congelan con el fin de retener el conocimiento visual original, optimizando únicamente el subconjunto de parámetros temporales inyectados.³²

Posicionamiento Temporal y Convoluciones Adaptativas 3D

La capacidad de extrapolación temporal en los modelos de difusión de video tradicionales se ve severamente limitada por el tipo de codificación posicional empleado.³² Mientras que los modelos estándar como SVD utilizan codificaciones de posición fijas basadas en funciones trigonométricas estáticas que impiden al modelo sintetizar secuencias que superen la ventana de entrenamiento (como el límite clásico de 25 fotogramas de SVD), metodologías post-ajuste como **ExVideo** modifican la arquitectura inyectando adaptadores dinámicos³²:

- **Embeddings Posicionales Trainables:** Se reemplazan las funciones trigonométricas estáticas por vectores de posición entrenables que pueden interpolarse analíticamente para acomodar longitudes temporales variables.³²

- **Capa Convolutiva 3D Adaptativa de Identidad (Adaptive Identity 3D Conv):** Se inyecta un módulo convolutivo 3D residual configurado como un mapeo de identidad en los pasos iniciales del ajuste.³² Esta capa aprende dinámicas de movimiento de largo alcance durante el entrenamiento de post-ajuste, asumiendo un costo paramétrico marginal (solo añade 25.8M de parámetros entrenables, representando el 2.9% de la U-Net base).³²

Técnicas de Control de Movimiento

La evolución de estas arquitecturas ha permitido integrar mecanismos de guiado explícitos para controlar la dinámica del video generado³⁵:

1. **Control de Trayectorias y Flujo Óptico (Go-with-the-Flow):** Propone correlacionar temporalmente la distribución del ruido latente inicializador en lugar de utilizar ruido gaussiano puramente desordenado.³⁵ Al extraer el mapa de flujo óptico de un video de referencia o una trayectoria definida por el usuario, el algoritmo deforma (*warps*) interactivamente el patrón de ruido entre fotogramas consecutivos mediante una dinámica de expansión y contracción de píxeles.³⁵ Esto permite forzar movimientos locales de objetos y desplazamientos de cámara específicos desde el mismo espacio de ruido latente inicial en inferencia sin necesidad de cambiar los pesos del denotador de video, que es tratado como una caja negra.³⁵
2. **Control Multimodal por Capas (Ctrl-Crash):** Utiliza un diseño de dos etapas donde primero se ajusta el modelo SVD base sobre un dominio especializado (como grabaciones viales) y posteriormente se acopla una red adaptadora de tipo ControlNet.³⁷ Esto permite condicionar la generación temporal basándose en una primera imagen de referencia estática, mapas de profundidad métricos consistentes generados por difusión (como UniVDC)³⁶, secuencias de cajas de delimitación (*bounding boxes*) para el guiado geométrico de los agentes y descriptores de intención semántica discretos, permitiendo simular de forma realista eventos raros e impredecibles como colisiones de vehículos o maniobras críticas de tráfico.³⁷
3. **Intersección de Trayectorias de Difusión (EIDT-V):** Es un enfoque agnóstico del modelo y libre de entrenamiento que utiliza la propiedad de intersección en las trayectorias de eliminación de ruido latente.³⁸ Un modelo de lenguaje grande (LLM) genera prompts descriptivos detallados para cada fotograma individual, mientras que otro LLM detecta las diferencias textuales entre ellos.³⁸ Con base en estas diferencias, se calcula una máscara de atención basada en CLIP que controla con precisión milimétrica cuándo debe conmutarse la influencia de los prompts en la cuadrícula latente de generación, proporcionando un equilibrio óptimo entre la variabilidad y la coherencia del movimiento de los fotogramas sintetizados.³⁸

A continuación se adjunta la visualización del esquema de inyección y extensión de bloques convolutivos 3D y de atención temporal en las capas de un modelo de difusión latente inflado:

!(<https://www.researchgate.net/figure/The-architecture-of-extended-temporal-blocks-in-Stable-Vi>)

Síntesis de Desempeño y Comparativa Arquitectónica

La elección de una arquitectura para la generación de video está determinada por el equilibrio que cada paradigma propone entre el coste computacional y la calidad del movimiento sintetizado.²²

En la siguiente tabla se analizan cuantitativamente los diferentes esquemas de atención temporal que implementan los modelos actuales para gestionar las dependencias temporales complejas de video ⁸:

Propiedad del Mecanismo	Atención 3D Completa (Full 3D Attention)	Atención Factorizada Espaciotemporal	Atención Matricial de Fotograma (Matrix Attention)	Atención Temporal Local (Local Temporal)
Complejidad Computacional	Cuadrática respecto a la secuencia total $\mathcal{O}((F \cdot H \cdot$ ³²	Lineal en el espacio de parches de fotograma $\mathcal{O}(F \cdot N + T$ ⁴⁰	Eficiente con operaciones nativas de matriz de fotograma ⁴⁰	Lineal con respecto a la longitud del volumen ⁴⁰
Capacidad ante Grandes Movimientos	Excelente (captura interacciones globales) ⁸	Deficiente (se limita a tokens en la misma posición espacial) ⁴⁰	Excelente (preserva la estructura global espacial entre fotogramas) ⁴⁰	Deficiente (sensible al desplazamiento o de píxeles) ⁴⁰
Consumo de Memoria VRAM	Crítico (requiere paralelismo secuencial o de contexto) ⁸	Bajo (procesamiento o desacoplado) ⁴¹	Moderado ⁴⁰	Extremadamente Bajo ⁴⁰
Fusión de Escala Global y Local	Óptima (procesamiento o unificado de todas las dimensiones) ⁸	Deficiente (separa espacialmente la información) ⁸	Excelente ⁴⁰	Limitada a vecindarios espaciales fijos ⁴⁰

Para consolidar una perspectiva sistémica del estado del arte en 2026, la siguiente tabla detalla los parámetros de diseño, las capacidades operativas y las restricciones de infraestructura de los principales modelos que lideran la síntesis de video actual ⁵:

Métrica y Parámetro Operativo	OpenAI Sora	CogVideoX -5B	Stable Video Diffusion (SVD 2.0)	Google Lumiere	Open-Sora 2.0
Longitud Máxima Generada	60 segundos ¹³	10 segundos ⁸	60 segundos ⁵	5 segundos ²⁶	Variable (hasta 15 s) ⁴²
Tasa de Fotogramas (FPS)	30 fps ¹¹	16 fps ⁸	Variable (7-25 fps) ⁴³	16 fps ²⁶	Variable (8 / 16 fps) ⁸
Resolución Máxima Nativa	1080p (Alta Definición) ¹³	768 × 1360 píxeles ⁸	Variable (ej. 1024 × 576) ⁴³	1024 × 1024 píxeles ²⁸	Variable adaptable ¹⁷
Mecanismo de Compresión	Spacetime Latent Patches ¹¹	3D Causal VAE ⁸	Image VAE preentrenado con decodificador temporal ²¹	Reducción de escala temporal directa en STUNet ²⁵	VAE nativo de video de alta compresión ¹⁷
Costo Estimado de Entrenamiento	Masivo (Cifras de supercómputo propietarias) ¹¹	Elevado (Entrenamiento a gran escala) ⁸	Moderado-Alto ³⁷	Propietario (Google Research) ⁴⁴	Altamente Optimizado (Aprox. \$200K de cómputo) ⁴²
Uso Principal / Dominio	Generalista de simulación física y digital ¹³	T2V de código abierto de alta consistencia ⁸	T2V / I2V e integración en flujos locales de ComfyUI ⁵	T2V, inpainting, cinemagraphs y estilización ²⁵	Replicación económica de Sora para la comunidad ¹⁷

En conclusión, la evolución de los modelos de generación de video demuestra que no existe una única arquitectura ganadora, sino un ecosistema donde los transformadores espaciotemporales (como Sora y CogVideoX) consolidan el camino hacia la simulación general de entornos físicos a gran escala ⁸, mientras que las optimizaciones en U-Nets convolucionales factorizadas (como Lumiere) y la inyección eficiente de parámetros temporales (SVD) aseguran la viabilidad, el control detallado de la animación y la accesibilidad computacional directa para los creadores de contenido visual y la investigación de código abierto.⁵

Trabajos Citados:

1. Generative AI for Text-to-Video Generation: Recent Advances and Future Directions - MDPI, accessed June 2, 2026, <https://www.mdpi.com/2673-6470/6/1/23>
2. (PDF) Bibliometric analysis and review of AI-based video generation: research dynamics and application trends (2020–2025) - ResearchGate, accessed June 2, 2026, https://www.researchgate.net/publication/393021949_Bibliometric_analysis_and_review_of_AI-based_video_generation_research_dynamics_and_application_trends_2020-2025
3. Bibliometric analysis and review of AI-based video generation: research dynamics and application trends (2020–2025), accessed June 2, 2026, <https://d-nb.info/1375031627/34>
4. Artificial Intelligence in Multimedia Content Generation: A Review of Audio and Video Synthesis Techniques - ResearchGate, accessed June 2, 2026, https://www.researchgate.net/journal/Journal-of-the-Society-for-Information-Display-1938-3657/publication/398318822_Artificial_Intelligence_in_Multimedia_Content_Generation_A_Review_of_Audio_and_Video_Synthesis_Techniques/links/69313d4d9aa6b4649dbcb7e9/Artificial-Intelligence-in-Multimedia-Content-Generation-A-Review-of-Audio-and-Video-Synthesis-Techniques.pdf?origin=journalDetail
5. Stable Diffusion 2026: Model Specs & VRAM Hardware Guide - AI Tools DevPro, accessed June 2, 2026, <https://aitoolsdevpro.com/ai-tools/stable-diffusion-guide/>
6. Ingredients: Blending Custom Photos with Video Diffusion Transformers - arXiv, accessed June 2, 2026, <https://arxiv.org/html/2501.01790v1>
7. NeurIPS Poster SF-V: Single Forward Video Generation Model, accessed June 2, 2026, <https://neurips.cc/virtual/2024/poster/95305>
8. CogVideoX: Text-to-Video Diffusion Models with An Expert Transformer - ICLR Proceedings, accessed June 2, 2026, https://proceedings.iclr.cc/paper_files/paper/2025/file/ce31378e9f41d8907e97dab172b6c559-Paper-Conference.pdf
9. What Is Stable Diffusion 3? Stability AI's Next-Gen Image Model - MindStudio, accessed June 2, 2026, <https://www.mindstudio.ai/blog/what-is-stable-diffusion-3-stability-ai>
10. From Image to Video: An Empirical Study of Diffusion Representations - arXiv, accessed June 2, 2026, <https://arxiv.org/html/2502.07001v1>
11. OpenAI Sora's Technical Review - Jianing Qi, accessed June 2, 2026,

- <https://j-qi.medium.com/openai-soras-technical-review-a8f85b44cb7f>
12. Generative Video Creation: Sora by OpenAI is Here - Codemotion, accessed June 2, 2026, <https://www.codemotion.com/magazine/ai-ml/generative-video-creation-sora-by-openai/>
 13. Video generation models as world simulators | OpenAI, accessed June 2, 2026, <https://openai.com/index/video-generation-models-as-world-simulators/>
 14. OpenAI Sora: Transform Text to Video Seamlessly, accessed June 2, 2026, <https://viso.ai/deep-learning/openai-sora/>
 15. Latte: Latent Diffusion Transformer for Video Generation - arXiv, accessed June 2, 2026, <https://arxiv.org/html/2401.03048v2>
 16. This Week in AI: weekly AI Updates - YourGPT Blog, accessed June 2, 2026, <https://yourgpt.ai/blog/updates/this-week-in-ai-weekly-ai-updates>
 17. Open-Sora: Sora Replication Solution with 46% Cost Reduction, Sequence Expansion to Nearly a Million - HPC-AI Tech, accessed June 2, 2026, <https://company.hpc-ai.com/blog/open-sora>
 18. OpenAI Sora Text to Video: 2026 Full Review & Tutorial, accessed June 2, 2026, <https://resource.digen.ai/openai-sora-text-to-video-2026-update/>
 19. The overall encoding pipeline of LMTV-DM. Given a set of frames, the... - ResearchGate, accessed June 2, 2026, https://www.researchgate.net/figure/The-overall-encoding-pipeline-of-LMTV-DM-Given-a-set-of-frames-the-selected-frames_fig4_392372095
 20. CVPR Poster Improved Video VAE for Latent Video Diffusion Model - CVPR 2026, accessed June 2, 2026, <https://cvpr.thecvf.com/virtual/2025/poster/33447>
 21. Improved Video VAE for Latent Video Diffusion Model - arXiv, accessed June 2, 2026, <https://arxiv.org/html/2411.06449v1>
 22. Taming Diffusion Transformer for Efficient Mobile Video Generation in Seconds, accessed June 2, 2026, https://snap-research.github.io/mobile_video_dit/
 23. HIGH-QUALITY JOINT IMAGE AND VIDEO TOKENIZATION WITH CAUSAL VAE - ICLR Proceedings, accessed June 2, 2026, https://proceedings.iclr.cc/paper_files/paper/2025/file/03df5246cc78af497940338dd3eacbaa-Paper-Conference.pdf
 24. Pyramidal Spectrum: Frequency-based Hierarchically Vector Quantized VAE for Videos, accessed June 2, 2026, https://www.researchgate.net/publication/400587819_Pyramidal_Spectrum_Frequency-based_Hierarchically_Vector_Quantized_VAE_for_Videos
 25. Lumiere: A Space-Time Diffusion Model for Video Generation - Hugging Face, accessed June 2, 2026, <https://huggingface.co/papers/2401.12945>
 26. Lumiere: A Space-Time Diffusion Model for Video Generation - arXiv, accessed June 2, 2026, <https://arxiv.org/html/2401.12945v1>
 27. Lumiere — The most promising Text-to-Video model yet from Google - AI Bites, accessed June 2, 2026, <https://www.ai-bites.net/lumiere-the-most-promising-text-to-video-model-yet-from-google/>
 28. Google's Lumiere has created a new paradigm for text-to-video AI - Freethink,

accessed June 2, 2026,

<https://www.freethink.com/robots-ai/googles-lumiere-has-created-a-new-paradigm-for-text-to-video-ai>

29. Paper Review: Lumiere: A Space-Time Diffusion Model for Video Generation - GoPenAI, accessed June 2, 2026,
<https://blog.gopenai.com/paper-review-lumiere-a-space-time-diffusion-model-for-video-generation-9b83076b03c7>
30. Diffusion Models for Video Generation | Lil'Log, accessed June 2, 2026,
<https://lilianweng.github.io/posts/2024-04-12-diffusion-video/>
31. Space-Time UNet (STUNet) architecture (Bar-Tal et al., 2024; Lumiere, 2024) - ResearchGate, accessed June 2, 2026,
https://www.researchgate.net/figure/Space-Time-UNet-STUNet-architecture-Bar-Tal-et-al-2024-Lumiere-2024_fig1_379089749
32. (PDF) ExVideo: Extending Video Diffusion Models via Parameter-Efficient Post-Tuning, accessed June 2, 2026,
https://www.researchgate.net/publication/381580434_ExVideo_Extending_Video_Diffusion_Models_via_Parameter-Efficient_Post-Tuning
33. The architecture of extended temporal blocks in Stable Video Diffusion.... - ResearchGate, accessed June 2, 2026,
https://www.researchgate.net/figure/The-architecture-of-extended-temporal-blocks-in-Stable-Video-Diffusion-We-replace-the_fig1_381580434
34. Motion-Adaptive Temporal Attention for Lightweight Video Generation with Stable Diffusion, accessed June 2, 2026, <https://arxiv.org/html/2603.17398v1>
35. Go-with-the-Flow: Motion-Controllable Video Diffusion Models Using Real-Time Warped Noise - arXiv, accessed June 2, 2026, <https://arxiv.org/html/2501.08331v2>
36. UniVDC: A Zero-Shot Unified Diffusion Framework for Consistent Video Depth Completion, accessed June 2, 2026,
<https://openreview.net/forum?id=3P2oSzQ8Db>
37. Ctrl-Crash: Controllable Diffusion for Realistic Car Crashes - arXiv, accessed June 2, 2026, <https://arxiv.org/html/2506.00227v1>
38. CVPR Poster EIDT-V: Exploiting Intersections in Diffusion Trajectories for Model-Agnostic, Zero-Shot, Training-Free Text-to-Video Generation, accessed June 2, 2026, <https://cvpr.thecvf.com/virtual/2025/poster/34867>
39. Towards Human-Centered and Efficient Video Synthesis: A Survey of Multimodal Diffusion Models - ResearchGate, accessed June 2, 2026,
https://www.researchgate.net/publication/396280293_Towards_Human-Centered_and_Efficient_Video_Synthesis_A_Survey_of_Multimodal_Diffusion_Models
40. FrameDiT: Diffusion Transformer with Frame-Level Matrix Attention for Efficient Video Generation - ResearchGate, accessed June 2, 2026,
https://www.researchgate.net/publication/401772480_FrameDiT_Diffusion_Transformer_with_Frame-Level_Matrix_Attention_for_Efficient_Video_Generation
41. PT-T2I/V: AN EFFICIENT PROXY-TOKENIZED DIF- - ICLR Proceedings, accessed June 2, 2026,
https://proceedings.iclr.cc/paper_files/paper/2025/file/79e02d85992d6ed51657e99a92fc3819-Paper-Conference.pdf

42. Open-Sora 2.0: Training a Commercial-Level Video Generation Model in \$200k - arXiv, accessed June 2, 2026, <https://arxiv.org/html/2503.09642v1>
43. AI Architect: Design your homes with Stable Diffusion | by Aashi Dutt - Medium, accessed June 2, 2026, <https://aashi-dutt3.medium.com/ai-architect-design-your-homes-with-stable-diffusion-b1c61644c61e>
44. Exploring Lumiere A Deep Dive into Advanced Video Generation | by The Ministry of AI, accessed June 2, 2026, <https://medium.com/@ThePromptIndex/exploring-lumiere-a-deep-dive-into-advanced-video-generation-86a337291a1f>
45. GitHub - zai-org/CogVideo: text and image to video generation: CogVideoX (2024) and CogVideo (ICLR 2023), accessed June 2, 2026, <https://github.com/zai-org/CogVideo>